




|1er Cuatrimestre - 3er Año

|MÓDULO - Técnicas de PROCESAMIENTO DEL HABLA

|Docente - GIUDICE BOJANICH Rubén Emmanuel

|Grupo - VisionNet

// ABP - INFORME //

Integrantes de Grupo:

- | | | |
|---------------------------|------------|------------------------|
| • Guaraz Emanuel | 38.276.061 | Github |
| • Direni Carlos | 28.117.281 | Github |
| • Testa Andrea Paola | 25.442.630 | Github |
| • Villalba Valeria Nieves | 26.970.862 | Github |
| • Allende Olmedo Nicolás | 35.871.057 | Github |
| • García Carlos | 40.518.523 | Github |
| • Moreno Raúl | 29.201.107 | Github |

Link al Colab:

[ABP_Proc_Habla.ipynb](#)

Link al Video: [Video Proyecto VisionNet](#)

PROPUESTA 1: "Voz Activa"

1. NOMBRE DEL PROYECTO:

Voz Activa SISTEMA DE REPORTE DEL CLIMA S.I.M.A:


Prototipo de reconocimiento de comandos de voz personalizado para asistencia tecnológica, para informar el estado del tiempo en la Ciudad de Río Tercero, desarrollado en Google Colab en 4 semanas.

(Qué: sistema de reconocimiento adaptado / Cómo: pipeline DSP + ML ligero en Colab / Cuándo: sprint de 4 semanas)

2. TIPO DE PROYECTO: Tecnológico con impacto sociocomunitario.

3. ESPACIO CURRICULAR PARTICIPANTE: Procesamiento Digital de Señales de Audio

4. EJES TEMÁTICOS / RED DE CONCEPTOS:



Competencias fortalecidas:

- Técnica: Implementación de pipeline audio→features→modelo en entorno cloud.
- Analítica: Interpretación de métricas de clasificación y matrices de confusión.
- Ética/Social: Diseño centrado en el usuario, privacidad de datos biométricos de voz.

5. PROBLEMÁTICA / NECESIDAD: "Los asistentes de voz comerciales están entrenados con patrones de habla 'típicos'. Personas con variaciones articulatorias (discapacidad motriz, acentos regionales fuertes, patologías del habla) enfrentan tasas de error >40%, lo que limita

su autonomía digital y acceso a servicios básicos. También aquellas personas con capacidad visual disminuida o no videntes, tienen serios problemas para acceder a cierto tipo de información valiosa, que podría ser útil para el día a día de cada una de ellas. La dificultad de acceder de forma sencilla a aplicaciones que brinden información climática de utilidad a la hora de realizar o desempeñar tareas fuera del hogar, o vitales para aquellas personas con alguna enfermedad, afección o condición, que pueda agravarse por las condiciones climáticas de su día a día, hace que la necesidad de conocer las condiciones atmosféricas, como temperatura, la humedad relativa, entre otros, sea vital para enfrentar la jornada fuera de casa en condiciones adversas".

6. FUNDAMENTACIÓN:

Pregunta	Desarrollo Esperado
¿Por qué este problema?	Combina un desafío técnico real (robustez acústica) con una brecha de inclusión digital documentada. Permite aplicar conceptos del Eje I y II en un caso de uso tangible.
¿Potencial del proyecto?	Prototipo replicable: puede escalarse a otros idiomas, variantes dialectales o necesidades específicas de rehabilitación fonoaudiológica.
¿Relevancia profesional?	Desarrolla habilidades en: procesamiento de señal en Python, extracción de features con librosa, entrenamiento de modelos interpretables y documentación técnica reproducible.
¿Impacto social?	Promueve autonomía, reduce dependencia de terceros y visibiliza la necesidad de tecnologías accesibles desde el diseño.

7. VISIÓN DEL PROYECTO + OBJETIVOS

- **Objetivo General:** Desarrollar un prototipo funcional en Google Colab para el reconocimiento personalizado de 3 comandos de voz, optimizado para patrones articulatorios diversos, en un plazo de 4 semanas.
- **Objetivos Específicos:**

1- Recopilar y preprocesar un mini-dataset balanceado (15-20 muestras por clase).

- Dataset documentado, audios normalizados a 16kHz/1.0s, consentimiento registrado

2- Implementar pipeline de extracción de features (MFCCs + métricas espectrales).

- Código modular en Colab, visualización de espectrogramas y distribución de features.

3- Entrenar y evaluar un modelo de clasificación ligero (RF o SVM).

- Accuracy $\geq 75\%$ en validación, matriz de confusión interpretada, análisis de errores

4- Documentar limitaciones técnicas y éticas del prototipo.

- Informe de 5-7 páginas con apartados de reproducibilidad, sesgos y mejoras futuras.

➤ **Metas:** Calidad (Accuracy $\geq 75\%$, latencia $< 2s$ en Colab) | Tiempo (4 semanas) | Cantidad (1 notebook funcional + informe + video demo de 2 min)

8. SELECCIÓN DE ACCIONES OBJETIVO ESPECÍFICO ACCIONES

1. Dataset personalizado

- Definir 3 comandos claros (ej: "encender", "apagar", "ayuda")
- Grabar 15-20 muestras por clase (propio equipo o voluntarios con consentimiento) • Aplicar pipeline Eje I: trim, normalización, resample, crop/pad
- Organizar en estructura clase/audio.wav + CSV de metadatos

2. Extracción de features

- Implementar MFCCs (13 coef + deltas) con librosa
- Agregar features espectrales: centroid, rolloff, flatness, energía RMS • Visualizar distribución por clase (boxplots, PCA 2D)
- Seleccionar features con mayor poder discriminativo

3. Modelado y evaluación

- Dividir datos: 70% train, 30% test (estratificado por clase)
- Entrenar Random Forest o SVM con scikit-learn
- Evaluar: accuracy, precisión, recall, F1-macro • Graficar matriz de confusión y analizar falsos positivos/negativos

4. Documentación y ética

- Redactar informe técnico (metodología, resultados, limitaciones)

- Incluir apartado de ética: consentimiento, anonimización, sesgos
- Grabar video demo mostrando flujo: grabación → predicción → resultado
- Subir Colab público y adjuntar informe PDF

9. CRONOGRAMA (4 SEMANAS)

CRONOGRAMA	SEMANA 1	SEMANA 2	SEMANA 3	SEMANA 4
Objetivo 1	Definición de comandos + protocolo de grabación + consentimiento	Grabación de muestras + preprocesamiento (trim, norm, resample)	Validación de calidad de audios + organización del dataset	Documentación de metadatos + reserva de dataset en Drive/GitHub
Objetivo 2	Revisión teórica de MFCCs y features espectrales	Implementación del extractor en Colab + visualización de espectrogramas	Análisis exploratorio (EDA) + selección de features	Optimización de pipeline + pruebas de consistencia
Objetivo 3	Diseño de división train/test + métricas de evaluación	Entrenamiento inicial (RF/SVM) + ajuste de hiperparámetros básico	Evaluación formal + matriz de confusión + análisis de errores	Iteración final + validación cruzada simple + reporte de métricas
Objetivo 4	Estructura del informe + revisión bibliográfica	Redacción de metodología y resultados técnicos	Redacción de limitaciones, ética y conclusiones	Video demo + revisión final + entrega de Colab + PDF

10. PRODUCTO FINAL:

Prototipo: Notebook de Google Colab ejecutable, con celdas de carga, procesamiento, entrenamiento, evaluación y visualización. Optativo: Script.py modular + interfaz mínima (Gradio/Streamlit) para prueba en navegador. Informe técnico: 5-7 páginas (APA 7°), incluyendo metodología, resultados, matriz de confusión, reflexión ética y enlaces al código. Video demostrativo: 2-3 minutos mostrando el flujo completo y un caso de uso simulado.

11. BIBLIOGRAFÍA (APA 7°)

Librosa Development Team. (2023). Librosa: Audio and music signal analysis in Python. <https://librosa.org/doc/latest/> Jurafsky, D., & Martin, J. H. (2024).

Speech and language processing (3rd ed. draft). <https://web.stanford.edu/~jurafsky/slp3/> Hugging Face. (2023). Transformers: State-of-the-art speech recognition.

<https://github.com/huggingface/transformers> NVIDIA. (2023). Deep learning examples for speech and audio. <https://github.com/NVIDIA/DeepLearningExamples> World Health

Organization. (2021). World report on disability. <https://www.who.int/teams/mental-health-and-substance-use/disability>



INFORME ABP:

S.I.M.A (Sistema de Monitoreo Ambiental)

Proyecto ABP: VozActiva

1. Resumen Ejecutivo y Conclusiones Generales

El proyecto VozActiva implementa un pipeline de extremo a extremo (end-to-end) para la clasificación automática de comandos de voz (audios en formato digital). A través del desarrollo del notebook (Google Colab), se evidencia cómo la correcta articulación entre los fundamentos bioacústicos y las técnicas de procesamiento digital de señales permite reducir la complejidad

de datos crudos de alta dimensionalidad hacia vectores de características compactas y altamente separables.

Conclusiones Clave del Proyecto:

- **Eficacia de los MFCC:** La extracción de 13 Coeficientes Cepstrales en la Escala Mel demuestra ser el estándar de la industria por una razón matemática y biológica clara: logra aislar la envolvente espectral (el tracto vocal del usuario que define el comando fonético) y descartar las variaciones acústicas redundantes o el ruido ambiental.
- **Garantía de Separabilidad:** La incorporación del análisis de componentes principales (PCA) antes del modelado sirve como una auditoría indispensable de los datos. Al proyectar la varianza de las características cepstrales, se confirma visualmente si las categorías de comandos de voz poseen límites geométricos claros.
- **Desempeño del Ensamble:** La utilización del algoritmo Random Forest aprovecha de manera robusta la información no lineal del espectro acústico, permitiendo un clasificador eficiente que asimila las firmas de voz con mínimos recursos computacionales en comparación con redes neuronales profundas (Deep Learning), resultando óptimo para entornos embebidos o de automatización local.

2. Análisis Detallado y Conclusiones por Celda de Ejecución

Instalación y Configuración del Entorno:

Se preparan las dependencias core del ecosistema de audio en Python: librosa para el procesamiento matemático de señales, scikit-learn para los modelos de machine learning y reducción dimensional, y matplotlib/seaborn para la analítica visual.

✓ **Estado: Operativo:** Garantiza un entorno reproducible donde los tipos de datos de audio se procesarán de forma estandarizada en memoria mediante arreglos multidimensionales de NumPy.

Montaje de Drive e Indexación del Dataset:

Se establece el canal de comunicación con el almacenamiento en la nube a través de la ruta absoluta de Google Colab. Se itera sobre el directorio para mapear el diccionario de categorías, el cual representa las variables objetivo (etiquetas discretas) que la IA deberá aprender a predecir.

✓ **Estado: Conectado.** El mapeo dinámico del diccionario CATEGORIES asegura la escalabilidad del proyecto: si se añaden nuevas carpetas de comandos de voz en Drive, el pipeline las asimila automáticamente sin alterar el código subsiguiente.

Análisis EDA: Tiempo vs. Frecuencia (Módulo 1):

Se implementa el **Eje I (Onda física a matrices)**. La señal se fuerza a un submuestreo de 16,000 Hz para evitar sobrecargar el modelo. Se aplica la Transformada de Fourier de Tiempo Corto (STFT) para calcular el espectrograma lineal de magnitud y se convierte a la escala logarítmica de decibelios (dB) mediante la ecuación:

$$\{dB\} = 20 \cdot \log_{10}$$

Nota: es el paso matemático necesario para preparar la señal de audio (el espectrograma) para que el modelo de IA pueda "ver" y aprender los patrones de energía de los comandos de voz de manera más eficiente

Cálculo en el Pipeline: después de obtener la *Transformada de Fourier de Tiempo Corto (STFT)*. Esto transforma la magnitud lineal del espectrograma en una representación en decibelios, la cual es estándar para analizar la energía de los sonidos en diferentes frecuencias a lo largo del tiempo

Análisis general de características del Dataset

Aquí se muestra un análisis fundamental de las señales de audio en dos dominios complementarios, el tiempo y la frecuencia:

Dominio del Tiempo (Onda Sonora - Gráfico superior):

Este gráfico representa la amplitud de la señal de audio a lo largo del tiempo. Los "picos" en

este gráfico indican momentos donde la energía sonora (volumen) es más alta. Un pico más alto significa un sonido más fuerte. En el habla, estos picos suelen coincidir con vocales o consonantes fuertes, donde hay una mayor vibración de las cuerdas vocales o una explosión de aire más potente.

Dominio de la Frecuencia (Espectrograma - Gráfico inferior):

Este gráfico muestra cómo la energía de la señal de audio se distribuye en diferentes frecuencias a lo largo del tiempo. Los "picos" aquí se manifiestan como áreas más brillantes o intensas (más claras, tendiendo al blanco o amarillo, dependiendo del mapa de color). Estas áreas brillantes indican una mayor concentración de energía en esas frecuencias específicas y en ese momento particular. En el habla, estas concentraciones de energía son cruciales y representan:

Formantes: Bandas de frecuencia donde la energía se concentra debido a la resonancia del tracto vocal. Son clave para distinguir vocales.

Armónicos: Múltiplos de la frecuencia fundamental (tono de voz), que le dan riqueza y timbre al sonido. Ruido/Fricción: En consonantes como la 's' o la 'f', verás energía distribuida en frecuencias más altas y con un patrón más difuso.

Los picos en el dominio del tiempo te dicen "cuán fuerte" es un sonido en un instante, mientras que los picos (áreas brillantes) en el espectrograma te dicen "qué frecuencias" componen ese sonido fuerte y cómo evolucionan esas frecuencias a lo largo del tiempo. Ambos son esenciales para comprender y procesar el habla.

✓ Conclusión: El gráfico de onda confirma que la voz es continua y variable. El espectrograma revela matemáticamente la densidad espectral de energía: permite identificar visualmente las bandas de frecuencia donde se concentra la fonética del comando y la presencia de armónicos, sirviendo como diagnóstico esencial para evaluar la calidad de grabación y el ruido de fondo.

Análisis exploratorio de datos (EDA) por cada clase separada:

Nos permite comparar visualmente las características de audio entre las diferentes categorías

de comandos de voz ('clima', 'reporte', 'et').

El gráfico de la forma de onda (dominio del tiempo) para el audio, nos muestra la amplitud de la señal a lo largo del tiempo. Presta atención a la duración de los picos, la densidad de la señal y cómo varían en fuerza (altura) entre diferentes comandos (cómo cambian los picos de amplitud y la duración de las sílabas). Por ejemplo, un comando más largo o con más sílabas tendrá un patrón de onda más extendido.

El Espectrograma (dominio de la frecuencia) para el mismo audio. Este es el gráfico más revelador. Aquí se observa cómo la energía de la señal se distribuye en diferentes frecuencias a lo largo del tiempo para cada comando. Las áreas más brillantes o de color más intenso indican dónde se concentra la energía. Estas concentraciones de energía (conocidas como formantes y armónicos) son las características acústicas distintivas que el modelo de Random Forest utilizará para diferenciar entre 'clima', 'reporte' y 'estado del tiempo'.

Curva de la Escala Mel (Módulo 2)

Mapea de forma teórica y visual la transición entre la frecuencia física externa (Hz) y la respuesta perceptual del oído humano (Mels), utilizando la modelación matemática citada en el módulo:

$$M(f) = 1127 \cdot \ln\left(1 + \frac{f}{700}\right)$$

Nota: Se utiliza en el procesamiento de señales de audio para convertir las frecuencias físicas reales (medidas en Hertz, Hz) a una escala denominada **Mels**, que se asemeja mucho más a cómo el oído humano percibe realmente el sonido.

Se basa en cómo el oído humano percibe las frecuencias, no en cómo las frecuencias se distribuyen linealmente en el espectro físico. Mapea las frecuencias lineales (Hz) a una escala que se asemeja más a cómo nuestro sistema auditivo procesa el sonido.

Características más Relevantes: En el habla, la información más crítica para distinguir sonidos (como las vocales y muchas consonantes) reside en las frecuencias bajas y medias. Al usar la escala Mel, se le da más peso o "resolución" a estas frecuencias que son

perceptualmente más importantes para el reconocimiento del habla.

Robustez: Las características basadas en la escala Mel son más robustas a variaciones en el volumen y el ruido, ya que se centran en las propiedades tímbricas del sonido que son más estables.

En la parte izquierda de la curva (frecuencias bajas), verás que un pequeño cambio en Hz produce un cambio relativamente grande en Mel. Esto significa que a bajas frecuencias, somos muy sensibles a las diferencias de tono.

A medida que la curva se aplana en la parte derecha (frecuencias altas), un cambio mucho más grande en Hz es necesario para producir el mismo cambio en Mel. Esto indica que a altas frecuencias, nuestra percepción de las diferencias de tono disminuye significativamente.

✓ Conclusión: Justifica neurobiológicamente el diseño de la arquitectura. Dado que la cóclea humana procesa la audición de manera no lineal (alta resolución en frecuencias bajas para comprender el habla, baja resolución en agudos), los modelos de IA deben priorizar los rangos de 0 a 4000 Hz. Esto fundamenta el paso hacia el banco de filtros Mel.

Pipeline de MFCC y Mapa Cepstral (Eje 2)

Se procesa el dataset completo extrayendo 13 Coeficientes Cepstrales Mel (MFCC). Mediante la Transformada Inversa de Coseno Discreta (DCT) aplicada sobre el espectrograma Mel logarítmico, se logra la 'deconvolución' de la señal, separando la fuente de excitación de la respuesta del tracto vocal. Los vectores se promedian temporalmente para obtener una firma estática por audio.

Cada columna vertical del mapa de calor corresponde a un pequeño segmento de tiempo del audio, y cada fila horizontal representa un coeficiente MFCC. Los diferentes colores o intensidades en el gráfico indican la magnitud de estos coeficientes. Las variaciones en color y patrón a lo largo del tiempo capturan cómo las características espectrales del sonido cambian, lo cual es esencial para distinguir palabras.

El modelo de Random Forest entrenado utiliza estos patrones de MFCCs como entrada. Al observar cómo cambian estos coeficientes a lo largo del tiempo, el modelo aprende a

diferenciar entre los comandos de voz como 'clima', 'reporte' y 'estado del tiempo'. Un mapa de calor con patrones claros y distintivos para cada comando facilita que el modelo clasifique con alta precisión, como se ha demostrado en los resultados del informe de clasificación y la matriz de confusión. En resumen, este gráfico es la visualización de las características que permiten al modelo 'entender' qué comando se ha dicho.

✓ **Conclusión:** El mapa de calor resultante es la "huella dactilar fonética" del comando de voz. El pipeline logra comprimir miles de puntos de datos de presión de aire temporales en una matriz ultra-compacta de solo 13 dimensiones, eliminando la variabilidad de duración del audio y reteniendo la pura identidad fonética que necesita el clasificador.

Auditoría del Espacio Latente (PCA)

Se aplica la técnica de Análisis de Componentes Principales (PCA) para reducir la dimensionalidad de las características de 13 a un espacio bidimensional (2D) que sea interpretable por el ojo humano, proyectando las componentes con mayor varianza matemática.

Nos permite visualizar la separabilidad de las clases de comandos de voz ('clima', 'reporte', 'et'). El gráfico de "Visualización del Espacio de Características (PCA)" nos muestra los datos de audio, que originalmente tenían 30 dimensiones (MFCCs, deltas y características espectrales), reducidos a solo dos componentes principales (PC1 y PC2) para que podamos verlos en un plano 2D. Cada punto en el gráfico representa un archivo de audio, y su color y estilo indican a qué categoría pertenece.

Buena Separabilidad: Si observamos los grupos de puntos de diferentes colores, lo ideal es que estén bien separados y formen clusters distintos. Una buena separación visual en este gráfico indica que las características que has extraído (MFCCs y otras) son efectivas para diferenciar entre los comandos de voz.

Implicación para el Modelo: Cuando los clusters están claramente definidos y hay poca superposición entre ellos, significa que el modelo de Machine Learning (en tu caso, el Random Forest) tendrá una tarea más fácil al aprender a clasificar nuevos audios. Los límites de decisión entre las clases serán más claros, lo que generalmente conduce a una mayor precisión en el reconocimiento.

Identificación de Dificultades: Si, por el contrario, los puntos de diferentes categorías se mezclaran significativamente, indicaría que las características extraídas no son lo suficientemente distintivas, o que podría haber ambigüedad en los audios, lo que dificultará la clasificación del modelo.

✓ Conclusión: *El scatter plot de PCA actúa como el control de calidad matemático antes de entrenar la IA. Si los puntos se agrupan en clústeres separados según su etiqueta, se demuestra empíricamente que los MFCC contienen suficiente varianza interclase. Esto asegura que el clasificador posterior podrá trazar fronteras de decisión estables y precisas.*

Entrenamiento del Clasificador y Métricas de Evaluación

Se divide el dataset en entrenamiento (80%) y prueba (20%) de forma estratificada para mantener la proporción de clases. Se entrena un ensamble de árboles de decisión (Random Forest) con 100 estimadores. La evaluación se plasma en un reporte métrico de clasificación (Precisión, Recall, F1-Score) y en una Matriz de Confusión.

RESULTADOS DEL INFORME DE CLASIFICACIÓN Y UNA MATRÍZ DE CONFUSIÓN:

Informe de Clasificación:

Precisión: Para cada clase (clima, reporte, et), te dice qué porcentaje de las predicciones de esa clase fueron correctas. Por ejemplo, si el modelo predijo 'clima' 10 veces y 8 fueron realmente 'clima', la precisión es 0.80.

Recall (sensibilidad): Para cada clase, te dice qué porcentaje de las instancias reales de esa clase el modelo logró identificar. Si había 10 audios de 'clima' y el modelo detectó 9, el recall es 0.90.

F1-score: Es una medida que combina la precisión y el recall, siendo una media armónica. Es útil cuando tienes un desequilibrio de clases.

Support: Es la cantidad de instancias reales de esa clase en el conjunto de prueba.

Accuracy: La precisión global del modelo, es decir, el porcentaje de predicciones correctas sobre el total de predicciones. En tu caso, un 88%.

El modelo de **Random Forest** ha logrado una precisión global del 88%, lo cual es un resultado muy bueno para la tarea de reconocimiento de comandos de voz.

Observamos que:

- Las clases '**clima**' y '**reporte**' tienen un rendimiento muy sólido, con alta precisión y recall.
- La clase '**et**' (estado del tiempo) también tiene una buena precisión, pero un recall ligeramente menor (0.75), lo que sugiere que el modelo a veces confunde algunos audios de 'et' con otras clases, aunque cuando predice 'et', lo hace con alta fiabilidad.

La matriz de confusión nos permitiría identificar exactamente cuáles fueron esas confusiones.

Por ejemplo, podríamos ver cuántos audios de 'et' fueron erróneamente clasificados como 'clima' o 'reporte'. Este rendimiento indica que las características que extraemos de los audios (MFCCs, deltas, etc.) son muy discriminatorias y el modelo Random Forest es efectivo en aprender los patrones para diferenciar los comandos de voz asignados. Es un paso sólido para este sistema de asistencia tecnológica.

✓ Conclusión: La matriz de confusión permite auditar qué comandos de voz específicos tienden a confundirse entre sí debido a similitudes fonéticas en el espacio cepstral. El balance de métricas de precisión y recall válida la robustez del sistema, asegurando que la automatización de comandos de voz responde de forma fiable y con alta capacidad de generalización ante nuevos usuarios.

Enlace al poster: [ABP Procesamiento HABLA](#)