




|1er Cuatrimestre - 3er Año

|MÓDULO - Técnicas de PROCESAMIENTO DEL HABLA

|Docente - GIUDICE BOJANICH Rubén Emmanuel

|Grupo - VisioNet

// Evidencia Nº 1 //

Integrantes de Grupo:

- | | | |
|---------------------------|------------|------------------------|
| • Guaraz Emanuel | 38.276.061 | Github |
| • Direni Carlos | 28.117.281 | Github |
| • Testa Andrea Paola | 25.442.630 | Github |
| • Villalba Valeria Nieves | 26.970.862 | Github |
| • Allende Olmedo Nicolás | 35.871.057 | Github |
| • García Carlos | 40.518.523 | Github |
| • Moreno Raúl | 29.201.107 | Github |

Link al Colab: [TP1_Eje 1.ipynb](#)

TRABAJO PRÁCTICO INTEGRADOR EJE N°1

Procesamiento Digital de Señales de Audio

1.1: Muestreo y Teorema de Nyquist

a) Explicá con tus palabras qué es el muestreo y por qué es necesario digitalizar una señal de audio.

El muestreo es como tomar "fotografías" a intervalos regulares para convertir una señal continua en valores discretos. Y es necesario digitalizar la señal porque en la vida real la señal de audio es analógica (continuo e infinito) mientras que las computadoras sólo pueden procesar o entender dígitos (valores discretos y finitos).

El teorema de Nyquist nos dice que la frecuencia de muestreo debe ser al menos el doble de la frecuencia máxima ($f_s \geq 2 \times f_{\max}$)

b) Una señal de voz tiene componentes de frecuencia hasta 4000 Hz.
¿Cuál es la frecuencia de muestreo mínima teórica necesaria?

Según el Teorema de Nyquist-Shannon, la frecuencia de muestreo debe ser al menos el doble de la frecuencia máxima de la señal. Por lo tanto, $4000 \text{ Hz} \times 2 = 8000 \text{ Hz}$.

Si muestreamos a 6000 Hz, ¿qué problema podríamos tener?

Tendríamos el problema de aliasing (o solapamiento). Al ser 6000 Hz una frecuencia menor al mínimo de 8000 Hz exigido por Nyquist, las frecuencias originales mayores a 3000 Hz (la mitad de 6000 Hz) no podrán representarse correctamente y se "plegarán" hacia abajo, generando frecuencias falsas y distorsionando severamente el audio.

¿Por qué el audio de teléfono usa 8000 Hz?

Porque la mayor parte de la información que permite comprender el habla humana (inteligibilidad) está concentrada en el rango de frecuencias de hasta 4000 Hz. Al transmitir solo hasta 4000 Hz, se ahorra muchísimo ancho de banda en las redes telefónicas, y según el Teorema de Nyquist, muestrear ese rango con exactitud requiere justamente 8000 Hz.

c) Investigá: ¿por qué el audio de CD usa 44100 Hz y no 40000 Hz exactamente?

El oído humano puede percibir frecuencias hasta aproximadamente 20.000 Hz. Para capturar este rango según Nyquist, se necesitan mínimamente 40.000 Hz. Sin embargo, en el mundo físico real, los filtros analógicos previos a la digitalización (filtros anti-aliasing) no pueden cortar bruscamente el sonido a partir de los 20.000 Hz; necesitan una "banda de transición". Usar 44100 Hz mueve la frecuencia límite (frecuencia de Nyquist) a 22050 Hz, dejando un margen seguro de 2050 Hz para que el filtro atenúe progresivamente la señal y no ensucie el espectro audible.

1.2. Cuantización y Resolución

a) Compará dos grabaciones de la misma señal:

Grabación A: 8 bits de resolución

Grabación B: 16 bits de resolución

Explicá:

¿Cuántos niveles de amplitud tiene cada una?

La Grabación A tiene $2^8 = 256$ niveles. La Grabación B tiene $2^{16} = 65536$ niveles.

¿Cuál tendrá mejor calidad y por qué?

La grabación B tiene muchísima mejor calidad. Al tener más de 65 mil niveles para representar la amplitud

¿Qué desventaja tiene la grabación B?

La desventaja es que la grabación B tendrá exactamente el doble del peso y por lo tanto requerirá más ancho de banda para su procesamiento y transmisión.

b) Si una señal tiene un rango dinámico de 96 dB, ¿cuántos bits mínimos se necesitan para representarla sin perder información? (Pista: cada bit aporta ~6 dB)

Dado que cada bit aporta aproximadamente 6 dB de rango dinámico: $96 \text{ dB} / 6 \text{ dB por bit} = 16 \text{ bits}$.

1.3. Aliasing

a) Describí el fenómeno de aliasing con un ejemplo cotidiano (puede ser el de la rueda de carroza en películas u otro que conozcas).

El ejemplo más clásico es el efecto "de las ruedas de carreta" en el cine. Cuando ves en una película a un vehículo o a un helicóptero moviéndose hacia adelante pero las ruedas o las aspas parecen estar girando lentamente hacia atrás. Esto ocurre porque la cámara "muestrea" la escena tomando típicamente 24 fotografías por segundo; si la rueda da más de media vuelta entre una foto y la siguiente, la cámara "malinterpreta" la posición y genera la ilusión visual de que gira en sentido contrario (una frecuencia de movimiento falsa).

b) Matemáticamente:

Señal original: 7000 Hz

Frecuencia de muestreo: 8000 Hz

¿Qué frecuencia "falsa" aparecerá después del muestreo?

Mostrá el cálculo

Debido a que la frecuencia original supera la Frecuencia de Nyquist ($f_s/2 = 4000 \text{ Hz}$), ocurrirá aliasing.

La frecuencia falsa se calcula mediante el valor absoluto de la diferencia entre la frecuencia de muestreo y la frecuencia de la señal original:

$$= 8000 \text{ Hz} - 7000 \text{ Hz} = 1000 \text{ Hz}$$

En la grabación digital se escuchará un "tono fantasma" de 1000 Hz que no existía en el audio real.

c) ¿Cómo se puede prevenir el aliasing?

Existen principalmente dos estrategias fundamentales para evitar este fenómeno:

Filtro Anti-aliasing (Filtro pasa-bajos analógico): Antes de que la señal analógica llegue al conversor, se hace pasar por un filtro físico que elimina o atenúa drásticamente todas las frecuencias que superen la Frecuencia de Nyquist ($f_s/2$). De esta forma, no quedan frecuencias "ilegales" que puedan plegarse y generar ruido fantasma.

Sobremuestreo (Oversampling): Consiste en muestrear la señal a una frecuencia mucho más alta de la estrictamente necesaria. Esto crea una "banda de transición" más ancha, permitiendo que los filtros sean más eficientes y se alejen del rango de frecuencias audibles, evitando ensuciar el espectro.

1.4: Dominio del Tiempo vs. Frecuencia

Característica	Dominio del Tiempo	Dominio de la Frecuencia
¿Qué muestra?	La variación de la amplitud de la señal a lo largo del tiempo.	La distribución de la energía o magnitud en diferentes frecuencias.
Herramienta principal	Oscilograma / Forma de onda.	FFT (Transformada Rápida de Fourier).
Ejemplo de uso	Detectar silencios o recortes (clipping).	Identificar el tono (pitch), armónicos o filtrar ruidos específicos.

b) ¿Qué es la Transformada de Fourier y por qué es importante?

La Transformada de Fourier es una herramienta matemática que descompone una señal compleja en sus componentes de frecuencia individuales (ondas simples de seno y coseno). Es fundamental en el análisis de audio porque permite pasar de ver "ruido" o formas de onda confusas a entender la "receta" del sonido: nos revela qué notas se están tocando, el timbre de una voz y permite realizar procesos esenciales como la compresión de audio o la extracción de características para IA.

c) Interpretación del espectro (440 Hz, 880 Hz, 1320 Hz)

Si se observa un pico muy alto en 440 Hz y picos menores en sus múltiplos exactos (880 Hz es 2×440 ; 1320 Hz es 3×440), se puede concluir lo siguiente sobre la señal:


- Es una señal periódica compleja (como la nota de un instrumento musical o una vocal humana).
- La frecuencia fundamental (el tono que percibimos) es de 440 Hz, que corresponde a la nota musical La4.

- Los picos en 880 Hz y 1320 Hz son sus armónicos, que son los que definen el timbre o la "calidad" del sonido.




Ejercicio 2.1: Generación y Análisis de Señales Sintéticas

Consigna: Generar tres señales diferentes para estudiar los efectos del muestreo y cuantización.
Python


Generación de señal "ANALÓGICA", de referencia







Elaboración de versión muestreada:





CUANTIZACIÓN DE LA SEÑAL fs1




ANÁLISIS SOBRE AUDIOS REALES




Preparación de Datos Crudos




Análisis Exploratorio - FFT y Espectros




COMPARACIÓN DE ESPECTROS PROMEDIO POR CLASES




Visualizaciones de Features por Clase




Pairplot de Features de Características Importantes



Heatmap de Correlación entre Features



Gráficos de proyección 2D



- 2. **Normalización:** Se ajustó la amplitud máxima a 1.0 para estandarizar la potencia.
- 3. **Segmentación:** Se dividieron los audios en fragmentos de igual duración (ej. 3 segundos).
- **Impacto:** Se logró una reducción del **20-30%** en datos irrelevantes (silencio) y una consistencia del **100%** en el formato de entrada.

3. Análisis Exploratorio

- **Características distintivas:** Se observó que los sonidos más agudos presentan mayor energía en las bandas de frecuencia superiores del espectrograma.
- **Features discriminativas:** Los MFCC (Coeficientes Cepstrales en las Frecuencias de Mel) resultaron ser los más útiles, ya que capturan la "forma" del sonido de manera similar al oído humano. El Spectral Rolloff también ayudó a distinguir sonidos brillantes de sonidos opacos.
- **Separabilidad (PCA):** Al aplicar Análisis de Componentes Principales, se observó que las clases tienden a agruparse, aunque existe solapamiento en sonidos con timbres similares.

4. Conclusiones y Recomendaciones

- **¿Es adecuado el dataset?** Sí, es adecuado, pero requiere una limpieza profunda de ruidos externos antes de entrenar un modelo.
- **Mejoras propuestas:** Implementar Data Augmentation (agregar ruido blanco o cambiar levemente el tono) para que el modelo sea más robusto ante diferentes condiciones de grabación.
- **Features recomendadas:** Para un modelo de ML, recomendaríamos una combinación de MFCCs, Chroma Features (para contenido tonal) y Zero Crossing Rate (para detectar ruidos o percusiones).

Ejercicio 3.2: Reflexión Crítica

a) Analogía del Análisis Espectral

Si tuviera que explicárselo a alguien, usaríamos la **analogía de una receta de cocina**.

Imaginen que escuchan una canción o un sonido complejo: eso es el "plato terminado" (una torta). El **análisis espectral** es como tener un superpoder que nos permite desarmar esa torta y ver exactamente cuántos gramos tiene de harina, cuántos de azúcar y cuántos de chocolate.

En el audio, estos ingredientes son las **frecuencias**. El análisis nos dice qué tan "dulce" (frecuencias agudas) o qué tan "pesado" (frecuencias graves) es el sonido, permitiéndonos entender su composición interna en lugar de solo escuchar el resultado final.

b) El concepto más desafiante

Lo que más nos costó asimilar fue la Transformada de Fourier y el paso del dominio del tiempo al de la frecuencia.

Como venimos del mundo de la programación estructurada y la robótica, estamos acostumbrados a ver señales que fluyen segundo a segundo. Ver el audio como una "foto" estática de frecuencias nos resultaba abstracto.

¿Cómo lo superamos? Relacionándolo con nuestro trabajo en el aula. Empezamos a visualizar los datos como si fueran una matriz de notas musicales: en lugar de ver una línea que sube y baja, empezamos a verlo como un ecualizador de música donde cada barra representa una parte del sonido. Experimentar con la librería *Librosa* y ver gráficamente cómo un silbido se convierte en una línea brillante en un espectrograma fue el momento donde todo "hizo clic".

c) Recomendaciones para un equipo de recolección de datos

Basándonos en lo que vimos sobre la calidad del audio y los *outliers*:

1. **Estandarización del entorno:** Pediría que las grabaciones se realicen con el mismo **Sample Rate** (preferentemente 44,100 Hz y en formato WAV) y con la misma **profundidad (16 bits)** para evitar la pérdida de datos que genera el MP3.
2. **Diversidad controlada:** No solo recolectar voces perfectas; necesitamos ruidos de fondo reales (tráfico, viento, otras voces) para que la IA aprenda a filtrar lo importante.
3. **Etiquetado de silencios:** Ser muy estrictos en marcar dónde empieza y termina el habla real, para que el preprocesamiento de *trimming* no borre fragmentos importantes de las palabras.

d) Aplicación en el contexto real a nuestro Proyecto Final

En el marco de nuestro proyecto "Eco-Intelligence", estos conocimientos son fundamentales para transformar una estación meteorológica convencional en un sistema inteligente. La aplicación se divide en tres ejes clave:

1. **Monitoreo Acústico Ambiental:** La estación no sólo medirá variables climáticas tradicionales (temperatura, humedad), sino que integrará el procesamiento de señales para analizar el sonido del entorno. Por ejemplo, mediante el análisis de frecuencias, podríamos detectar la intensidad de la lluvia o ráfagas de viento basándonos en su firma sonora, sirviendo como una validación redundante de los sensores mecánicos.
2. **Mantenimiento Predictivo con IA:** Aplicando lo aprendido sobre *outliers* y desviación estándar, podemos programar la estación para que detecte anomalías

en el funcionamiento de sus propios componentes. Si un sensor empieza a entregar datos con ruido atípico, el sistema podrá identificarlo como un error de hardware antes de que afecte el promedio de las mediciones históricas.

3. **Impacto Educativo en Escuelas PRoA:** Como profesionales en formación y docentes, nuestro objetivo es que nuestros estudiantes vean que la IA no es solo texto o imágenes, sino una herramienta para interpretar el mundo físico. Aplicar el procesamiento de señales en una estación meteorológica real les permite entender cómo los datos analógicos del ambiente se convierten en arrays digitales, y cómo esos números pueden salvar vidas al predecir eventos climáticos en su propia localidad, Río Tercero o alrededores.-