




|1er Cuatrimestre - 3er Año

|MÓDULO - Técnicas de PROCESAMIENTO DEL HABLA

|Docente - GIUDICE BOJANICH Rubén Emmanuel

|Grupo - VisioNet

// EVIDENCIA II //

Integrantes de Grupo:

• Guaraz Emanuel	38.276.061	Github
• Direni Carlos	28.117.281	Github
• Testa Andrea Paola	25.442.630	Github
• Villalba Valeria Nieves	26.970.862	Github
• Allende Olmedo Nicolás	35.871.057	Github
• García Carlos	40.518.523	Github
• Moreno Raúl	29.201.107	Github

Link al Colab:

∞ TP2_Eje 2.ipynb

BITÁCORA CELDA N° 7

Análisis de la Actividad N° 1:

Al eliminar `StandardScaler`, la precisión del modelo SVM disminuye significativamente, lo que demuestra la importancia del escalado para este tipo de modelo.

El tiempo de entrenamiento sin escalado es comparable o incluso ligeramente menor. Esto puede deberse a la naturaleza de los datos o al tamaño reducido del dataset.

Accuracy:

Al no aplicar el escalado de características (`StandardScaler`), la precisión del modelo SVM en el conjunto de test disminuyó significativamente de aproximadamente 91.67% (con escalado) a 83.33% (sin escalado). Esto subraya la importancia crítica del escalado para los modelos SVM. Estos son sensibles a la escala de las características, y sin normalización, las características con rangos más grandes pueden dominar la función de distancia, afectando negativamente el rendimiento.

Tiempo de Entrenamiento:

El tiempo de entrenamiento disminuyó ligeramente de 0.0101 segundos (con escalado) a 0.0073 segundos (sin escalado). Si bien en datasets más grandes el entrenamiento sin escalado puede ser más lento debido a la dificultad del optimizador para converger, en este caso, la diferencia es mínima e incluso se observa una ligera reducción, lo que podría deberse a la simplicidad del dataset.

Análisis de la Actividad N° 2:

Ambos modelos (`Random Forest` y `SVM`) mostraron una resiliencia similar al ruido blanco. Las precisiones se mantuvieron idénticas al 91.67%, lo que sugiere que para la cantidad y el tipo de ruido aplicado, ninguno de los modelos se vio significativamente más afectado que el otro.

Es posible que el factor de ruido aplicado (`noise_factor=0.01`) no haya sido lo suficientemente alto como para mostrar una divergencia clara.

¿Por qué podrían tener una resiliencia similar?

1. Random Forest: Generalmente, los Random Forests son conocidos por su robustez al ruido y al sobreajuste debido a su naturaleza de ensemble (conjunto). Al promediar las predicciones de múltiples árboles de decisión entrenados en diferentes subconjuntos de datos y características, el impacto de una pequeña perturbación en algunas muestras tiende a ser mitigado. Si un árbol se ve afectado por el ruido, los demás árboles no afectados pueden compensarlo.

2. SVM: Los SVM, especialmente con kernels no lineales como el RBF, buscan un hiperplano que maximice el margen entre las clases. Si bien pueden ser sensibles a datos ruidosos o atípicos (outliers) que caen dentro del margen o son vectores de soporte, la robustez también puede depender de la complejidad de la separación de clases y de los parámetros C y γ . En este caso, la configuración y el ruido añadido no fueron suficientes para desestabilizar significativamente su capacidad de clasificación.

Análisis de la Actividad N° 3:

Se mantiene el accuracy, la precisión de ambos modelos (Random Forest y SVM) se mantuvo o incluso mejoró ligeramente con la reducción de características:

Random Forest: La precisión pasó de un 91.67% (con todas las características) a un 91.67% (con 20 características).

SVM: La precisión mejoró de un 91.67% (con todas las características) a un 95.83% (con 20 características).

Resulta Positivo, ya que muchas de las 86 características originales eran redundantes o no informativas para la tarea de clasificación. Al eliminar estas características menos relevantes, no solo se simplifican los modelos y se reduce el costo computacional, sino que en el caso del SVM, incluso se observa una ligera mejora en el rendimiento.

Las características seleccionadas ($F0_\mu$, $F1_\mu$, etc.) son aquellas que **SelectKBest** identificó como las más relevantes para diferenciar entre las clases, basándose en la prueba estadística F ($f_classif$). Para comprender por qué precisamente estos coeficientes de índice bajo resultan tan discriminatorios, es necesario considerar cómo se construyen los coeficientes cepstrales en las Frecuencias de Mel (MFCCs) y qué condiciones previas garantizan su calidad.

La calidad de estos coeficientes depende directamente de la correcta digitalización previa de la señal. El pipeline trabaja con **TARGET_SR = 16000** Hz, decisión que responde al **Teorema de Nyquist**: a 16.000 Hz, que se pueden representar frecuencias de hasta 8.000 Hz, siendo rango suficiente para audio ambiental y voz humana. Un *sample rate* insuficiente haría que los MFCCs capturen componentes de **aliasing**, introduciendo ruido en el vector de características y degradando el rendimiento de ambos modelos. La **cuantización** determina además la resolución con la que se representan las amplitudes, afectando especialmente a los coeficientes de índice bajo ($F0$, $F1$) que resultaron ser precisamente los más discriminativos en esta actividad.

La extracción de MFCCs no opera directamente sobre la señal en el dominio del tiempo. Internamente, aplica la **Transformada de Fourier (FFT)** para transformar cada ventana temporal al dominio de la frecuencia, identificando cuánta energía contiene cada componente frecuencial. Esta transformación es lo que permite distinguir que el ladrido de un perro concentra energía en frecuencias distintas a las de la lluvia o el viento — diferencia que Random Forest y SVM explotan para separar las cuatro clases. Entre la FFT y los coeficientes MFCC existe además un paso intermedio central: el **espectrograma de Mel**, que reescala el eje de frecuencias según la percepción auditiva humana, otorgando mayor resolución a las frecuencias bajas. La cadena completa de transformaciones es la siguiente:

Audio preprocesado → FFT por ventanas → Espectrograma de Mel
→ Escala logarítmica → DCT → MFCCs (43 coeficientes)
→ Media y σ por coeficiente → Vector de 86 features → RF / SVM

Principales Conclusiones:

La precisión de ambos modelos se mantuvo o incluso mejoró ligeramente con la reducción de características. Esto sugiere que muchas de las características originales eran redundantes o no aportaban información significativa, y que la selección de características fue efectiva. Reducir la dimensionalidad puede ayudar a simplificar el modelo y, en algunos casos, a prevenir el sobreajuste.

*Las características seleccionadas ($F0_\mu$, $F1_\mu$, etc.) son aquellas que **SelectKBest** identificó como las más relevantes para diferenciar entre las clases, basándose en la prueba estadística F ($f_classif$).*