


Tecnicatura:

TECNICATURA SUPERIOR EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL



|1er Cuatrimestre - 3er Año

|MÓDULO - Técnicas de PROCESAMIENTO DEL HABLA

|Docente - GIUDICE BOJANICH Rubén Emmanuel

|Grupo - VisioNet

// EVIDENCIA III //

Integrantes de Grupo:

- | | | |
|---------------------------|------------|------------------------|
| • Guaraz Emanuel | 38.276.061 | Github |
| • Direni Carlos | 28.117.281 | Github |
| • Testa Andrea Paola | 25.442.630 | Github |
| • Villalba Valeria Nieves | 26.970.862 | Github |
| • Allende Olmedo Nicolás | 35.871.057 | Github |
| • García Carlos | 40.518.523 | Github |
| • Moreno Raúl | 29.201.107 | Github |

ACTIVIDAD 1 — Fundamentos del Procesamiento de Voz

A. Pipeline Clásico vs. Sistemas End-to-End basados en LLMs

La transición del ASR modular y estadístico hacia arquitecturas neuronales integradas implica eliminar, reemplazar y conservar componentes específicos del pipeline clásico.

Componentes eliminados

- **Modelado acústico y de lenguaje por separado (GMM):** fusionados en una sola red neuronal que entiende acústica y semántica simultáneamente (ej. Whisper).
- **Alineamiento manual DTW (Dynamic Time Warping):** el mecanismo de Atención de los Transformers procesa el contexto global de forma paralela, eliminando esta necesidad.
- **Segmentación rígida de fonemas:** se elimina la dependencia de diccionarios de pronunciación y el mapeo explícito de fonemas a estados. El sistema mapea audio crudo o espectrogramas directamente a grafemas.

Componentes reemplazados

- **MFCC → Espectrogramas Log-Mel:** retienen más información ('detalles finos') que las redes neuronales pueden aprender a filtrar por sí mismas, frente a la reducción dimensional forzada de los MFCC.
- **HMM/GMM → Transformers con auto-atención:** los HMM se basaban en probabilidades estadísticas de transición entre estados secuenciales; los Transformers superan la 'barrera del tiempo' al enfocarse en partes relevantes del espectrograma sin importar su posición temporal.
- **Clustering fonético (K-Means/codebooks) → Representaciones latentes:** en lugar de agrupar vectores en unidades acústicas discretas, los modelos modernos comprimen la secuencia en vectores de contexto dentro del encoder.

Componentes conservados

- **Transformada de Fourier (FFT/STFT):** puente matemático indispensable que convierte el sonido del dominio del tiempo al de la frecuencia para que la IA lo 'vea' como espectrograma.
- **Preprocesamiento crudo:** Trimming (recorte de silencios), filtrado de ruido y normalización de amplitud garantizan datos consistentes en cualquier pipeline.
- **Escala Mel:** inspiración biológica que adapta las frecuencias a la audición humana, ayudando al modelo a priorizar información de habla por encima del ruido ambiental.
- **El tensor como salida:** convertir vibraciones físicas en una matriz numérica estructurada es el objetivo último de cualquier pipeline, independientemente de su modernidad.

Conclusión crítica: El sistema clásico describía el habla mediante reglas estadísticas y segmentación manual (enfoque descriptivo); el moderno aprende representaciones

profundas de forma autónoma (enfoque conexionista), resolviendo la variabilidad extrema del lenguaje mediante fuerza computacional y memoria global.

B. De Handcrafted Features a Embeddings Autosupervisados

El cambio de características diseñadas manualmente (MFCC, LPC, ZCR) a embeddings aprendidos (HuBERT, Wav2Vec) representa un nuevo paradigma en la noción misma de 'característica'.

Tres dimensiones del cambio

1. De la medición a la representación latente. Los MFCC 'destilan' el sonido imitando cómo el oído humano filtra frecuencias: son descriptivos y rígidos, el investigador decide a priori qué varianza importa. Los embeddings de HuBERT usan CNNs para extraer patrones locales y luego Transformers para predecir porciones enmascaradas del audio; la 'característica' no es una medida de algo conocido sino una representación matemática densa que captura la estructura subyacente sin etiquetas.

2. De la información local a la contextual. Un vector MFCC representa una ventana de 20-30 ms de forma aislada, sin memoria temporal intrínseca. Gracias al mecanismo de atención, el embedding de un segmento cambia según los segmentos que lo rodean: el fonema /s/ ya no tiene un valor fijo sino una representación dinámica que incorpora la influencia de toda la secuencia.

3. El fin del cuello de botella de la ingeniería manual. Si el experto descarta la fase de la onda, esa información se pierde para siempre. Los embeddings autosupervisados eliminan ese filtro restrictivo: al pasar de MFCC a espectrogramas Log-Mel y luego a embeddings aprendidos, el sistema retiene detalles finos que el modelo puede utilizar de formas que un humano no podría programar.

Dimensión	Handcrafted (Clásico)	Embeddings Autosupervisados
Naturaleza	Descriptiva (mediciones físicas/biológicas)	Inferencial (representaciones matemáticas)
Diseño	Manual por expertos — ingeniería de señales	Autónomo por datos — Deep Learning
Alcance	Local y estático (ventanas de tiempo)	Global y contextual (mecanismo de atención)
Riesgo principal	Pérdida de información (Bottleneck)	Opacidad (caja negra / explicabilidad)

Implicancias prácticas del cambio de paradigma

En la práctica, la transición a embeddings autosupervisados habilita capacidades que antes eran imposibles:

- **Transferencia cross-lingüística:** un embedding aprendido puede transferir conocimiento fonético entre idiomas, ya que captura estructuras profundas del lenguaje que trascienden los sistemas de escritura o pronunciación particulares.

- **Adaptación continua:** a diferencia de los MFCC —cuya ingeniería queda fija una vez diseñada— los embeddings pueden actualizarse con nuevos datos de forma incremental, adaptando el sistema a cambios en el habla del usuario (fatiga, emociones, patologías progresivas).
- **Interoperabilidad con LLMs de texto:** los vectores de embeddings de audio pueden proyectarse al mismo espacio latente que los embeddings de texto, lo que permite que un único modelo procese de forma unificada voz, texto e imagen sin etapas de traducción intermedias.
- **Detección de patrones emergentes:** el modelo puede descubrir correlaciones acústico-semánticas que ningún experto humano habría programado, como la relación entre el ritmo del habla y el estado emocional del hablante, sin haber sido explícitamente entrenado para ello.

Conclusión crítica: La 'característica' deja de ser una herramienta para explicar el sonido y se convierte en una herramienta para que la máquina entienda el sentido. Se pierde interpretabilidad humana directa, pero se gana capacidad de generalización y robustez ante la variabilidad extrema del habla que los métodos manuales nunca pudieron alcanzar.

C. Tokenización de Audio: el Puente Físico-Lógico

La tokenización no es un paso técnico menor sino el cambio ontológico fundamental que permite que una señal física e infinita sea procesada por una arquitectura lógica y discreta como la de los LLMs.

- **Incompatibilidad físico-lógica.** El sonido es continuo y de resolución infinita; los LLMs operan bajo lógica simbólica y discreta donde la unidad es el token. La tokenización traduce vibraciones en un 'alfabeto acústico' que el modelo puede leer como si fuera texto.
- **Colapso de la maldición de la dimensionalidad.** Una señal cruda típica contiene al menos 16.000 valores por segundo. La complejidad del mecanismo de Atención crece de forma cuadrática, lo que hace inviable procesar esa densidad directamente. La tokenización (ventaneo + cuantización vectorial) comprime miles de muestras en una secuencia finita de vectores densos, preservando solo la varianza fonética y lingüística relevante.
- **Habilitación de la atención global.** Para que el modelo asigne pesos de importancia a distintas partes del audio (ej. el inicio de una frase modifica el sentido del final), necesita unidades discretas 'ancla'. La tokenización fragmenta el flujo temporal en frames o tokens que el modelo puede relacionar como una secuencia con dependencia temporal.
- **Del modelado estadístico a la comprensión latente.** En modelos autosupervisados como HuBERT, el token de audio ya no representa solo una frecuencia sino un concepto dentro de un espacio matemático, habilitando la inferencia semántica directa y superando la barrera de la simple transcripción.

Comparativa: enfoques de tokenización de audio

Enfoque	Mecanismo	Ventaja	Limitación
Ventaneo clásico	Segmentación en frames de longitud fija (ej. 25 ms)	Simple, interpretable, bajo costo	Pierde dependencias de largo alcance; sensible a segmentación arbitraria

Cuantización vectorial (VQ)	Mapeo de vectores continuos a un codebook discreto (codewords)	Representación compacta y discreta compatible con LLMs	El codebook puede ser insuficiente para habla muy variable o dialectos minoritarios
Tokenización autosupervisada (HuBERT)	Clusters K-Means sobre representaciones intermedias como pseudo-etiquetas de entrenamiento	Aprende unidades acústicas sin etiquetas humanas; alta generalización	Alto costo computacional de preentrenamiento; menor interpretabilidad
Tokenización multimodal unificada	Proyección de embeddings de audio al espacio latente de texto (ej. SpeechGPT)	Permite procesamiento unificado voz-texto en un solo modelo	Requiere arquitecturas especializadas y alineamiento cuidadoso de espacios latentes

Conclusión crítica: La tokenización es el puente necesario porque transforma el caos acústico en estructura matricial. Sin ella, no habría forma de aplicar el aprendizaje por refuerzo ni la arquitectura Encoder-Decoder que permite a las máquinas no solo 'grabar' sonido, sino interpretar el lenguaje oculto en él.

ACTIVIDAD 2 — Fine-tuning para Educación Inclusiva

A. Estrategia de Ajuste: LoRA + Prompt-Tuning

Para adaptar un LLM de voz a estudiantes con patrones de habla no estándar (disartria, barreras lingüísticas) se propone LoRA como técnica principal y Prompt-tuning para el control semántico.

¿Por qué no fine-tuning completo?

- **Costo prohibitivo:** entrenar o ajustar completamente modelos fundacionales requiere supercomputación inaccesible para instituciones educativas.
- **Olvido catastrófico:** reentrenar todo el modelo con un corpus pequeño de habla con discapacidades hace que el sistema pierda su capacidad de generalización lingüística previa, vital para que el LLM siga entendiendo la estructura del lenguaje mientras aprende la acústica diversa.

Justificación de LoRA

- **Adaptación de bajo rango:** congela los pesos originales (ej. Wav2Vec 2.0 o Whisper) e inyecta matrices de descomposición de rango entrenables en las capas de atención, permitiendo aprender variaciones acústicas finas sin alterar el conocimiento lingüístico base.
- **Robustez ante escasez de datos:** los datasets de educación inclusiva son pequeños por la naturaleza específica de las discapacidades. LoRA es mucho más resistente al sobreajuste en escenarios de pocos datos que el fine-tuning completo.
- **Portabilidad:** permite crear 'perfiles de accesibilidad' intercambiables (pocos megabytes) cargables dinámicamente según el estudiante, democratizando el acceso a tecnología avanzada.

Complemento con Prompt-Tuning

- **Lectura Fácil:** mediante prompts específicos se guía al modelo para reducir la complejidad sintáctica y léxica de las respuestas para estudiantes con dificultades cognitivas, sin reentrenar el modelo para cada nivel educativo.

Nivel	Estrategia	Función en Educación Inclusiva
Acústico	LoRA	Reconocimiento de voces con patologías o acentos diversos sin perder generalización lingüística
Semántico	Prompt-tuning	Transformación de la salida a formatos accesibles (Lectura Fácil, simplificación sintáctica y léxica)
Gobernanza	Auditoría de sesgos	Monitoreo continuo para evitar que el ajuste introduzca prejuicios contra grupos minoritarios

Conclusión crítica: En un dominio donde la variabilidad extrema es la norma y los recursos computacionales son finitos, LoRA ofrece el equilibrio técnico necesario para garantizar la explicabilidad y transparencia exigidas por los marcos regulatorios europeos, permitiendo una IA que sirva al ser humano sin costos energéticos inasumibles.

B. Gestión de Datos Defectuosos: Acondicionamiento Robusto

La gestión de datos no es un paso periférico sino el núcleo de la generalización del modelo. Se abordan tres patologías críticas:

1. Datos escasos — Aumento sintético y transferencia

- **GANs:** generación de muestras artificiales que imitan características acústicas de la población objetivo (voces con patologías).
- **Data Augmentation dinámico:** Time Stretching (alterar velocidad sin cambiar tono) y Pitch Shifting expanden el corpus existente simulando niveles de fatiga o tipos de vocalización sin perder la etiqueta fonética original.
- **Aprendizaje por transferencia:** modelo preentrenado masivamente en habla estándar (Whisper/Wav2Vec) ajustado finamente en tareas del dominio educativo, aprovechando el conocimiento lingüístico previo para compensar la falta de audio específico.

2. Datos desbalanceados — Re-ponderación y sesgo consciente

- **Instruction Tuning:** mayor peso estadístico a las muestras de habla no estándar, obligando al mecanismo de Atención a enfocarse en rasgos fonéticos divergentes.
- **Balanceo sintético:** generación de ejemplos de categorías subrepresentadas para evitar que el modelo asuma que el habla atípica es simplemente 'ruido'.
- **Auditoría de equidad (Model Cards):** métricas de evaluación continua para detectar si el ajuste optimiza el rendimiento general a expensas de la precisión en estudiantes con discapacidades específicas.

3. Datos con ruido — Robustez acústica

- **Pipeline de limpieza agresiva:** Trimming estricto basado en decibels para eliminar regiones sin actividad vocal que inyectan entropía al tensor final.
- **PCAN (Per-Channel Amplitude Normalization):** promedia el ruido dinámico evitando que anomalías fuertes (como un portazo) cieguen la capacidad de inferencia de la red neuronal, frente a una normalización de amplitud básica.
- **Entrenamiento multi-condición (Noisy Training):** no basta con limpiar el ruido; se inyecta ruido ambiental controlado en las muestras limpias durante el entrenamiento, forzando al modelo a aprender invariantes fonéticos inmunes a la acústica del entorno.

Conclusión crítica: La estrategia no busca la 'perfección' de la señal sino la consistencia estadística del tensor estructurado. El ruido y la escasez se tratan como variaciones a modelar mediante técnicas de rango bajo (LoRA), convirtiendo el 'caos acústico' en sentido pedagógicamente útil.

C. Evaluación y Control de Sobreajuste

Se requiere un marco de validación que trascienda las métricas estándar de ML, garantizando que el modelo haya aprendido representaciones robustas y no haya memorizado patrones de ruido de grupos pequeños.

Dimensión	Métrica / Técnica	Propósito
Rendimiento acústico	WER desagregado por subgrupo	Detectar sesgos ocultos por tipo de discapacidad o acento regional — un 5% global puede ocultar un 40% en una minoría
Calidad semántica	BLEU / METEOR / ROUGE	Validar que la simplificación (Lectura Fácil) preserve la esencia del mensaje respecto a referencias humanas de calidad
Alucinaciones	Inferencia NLI	Verificar coherencia lógica: la respuesta generada debe ser consecuencia lógica de la entrada de voz
Sobreajuste	Leave-One-Speaker-Out + Early Stopping	Separar hablantes completos en validación; detener cuando la pérdida de validación sube mientras la de entrenamiento baja
Regularización	Dropout + L2	Forzar al modelo a aprender características fonéticas generales, no dependientes de muestras individuales
Accesibilidad semántica	Índice de Lectura Fácil	Verificar simplificación sintáctica y léxica para estudiantes con dificultades cognitivas
Explicabilidad	Attention Maps	Auditar qué partes del espectrograma (fonemas, tonos) guían la decisión del modelo
Transparencia	Model Cards	Documentar limitaciones ante diferentes patologías para que educadores sepan cuándo el sistema es confiable

Conclusión crítica: La evaluación en educación inclusiva no puede ser puramente matemática: debe incluir feedback humano de especialistas en fonética y educación, validando que el LLM no solo 'transcriba bien' sino que 'entienda y adapte' el conocimiento para eliminar barreras de aprendizaje sin excluir a las minorías acústicas.

ACTIVIDAD 3 — Despliegue en Producción

A. Latencia vs. Calidad: Compromisos Técnicos Inevitables

El despliegue real de sistemas ASR/TTS basados en LLMs enfrenta un dilema fundamental entre la complejidad computacional necesaria para la calidad y la necesidad de respuesta inmediata del usuario.

Dilema	La tensión	Compromiso real en producción
Tamaño del modelo(parámetros vs. velocidad)	Modelos de 175B-1T parámetros = comprensión profunda, pero cada parámetro incrementa linealmente la carga de cálculo por token	Modelos destilados de 1.5B-6.3B: menor generalización y razonamiento emergente a cambio de latencia aceptable
Atención global(cuadrática vs. tiempo real)	El Transformer mira simultáneamente todas las partes del audio para capturar contexto semántico, pero la complejidad crece de forma cuadrática con la longitud de la secuencia	Ventanas de atención locales o segmentación: mejora la latencia pero introduce riesgo de perder dependencias de largo alcance y coherencia prosódica
Integridad de la señal(calidad vs. velocidad)	Audio lossless (WAV, 44.1 kHz) exigido para entrenamiento rico; esa densidad inyecta latencia inasumible en producción	Remuestreo a 22.05 kHz y cuantización de pesos (32 bits → 8 bits): introduce ruido de cuantización y descarta información vital para voces con patologías
Arquitectura(Cloud vs. Edge)	Cloud: máxima calidad con supercomputadores, pero añade latencia de red. Edge: elimina latencia de red pero limita el modelo al hardware del dispositivo	Elección según caso de uso; es imposible tener la sabiduría de un LLM fundacional funcionando offline en un móvil — siempre hay un trade-off

Conclusión crítica: El despliegue real no busca la perfección sino la consistencia estadística. El compromiso inevitable es aceptar un umbral de error (WER) y simplificación del modelo a cambio de interacción fluida, entendiendo que la 'calidad' de laboratorio choca con la 'utilidad' en campo, donde la velocidad es la métrica reina para la satisfacción del usuario.

B. Privacidad Biométrica de la Voz

La voz permite suplantación de identidad mediante grabaciones mínimas. Garantizar que no se almacene ni se use indebidamente requiere que la privacidad esté integrada en la arquitectura misma del dato.

1. Descentralización: Edge Computing y Aprendizaje Federado

- **Procesamiento local (Edge):** los datos se procesan directamente en el dispositivo del usuario, eliminando la necesidad de enviar audio crudo a la nube y minimizando el riesgo de filtraciones masivas de datos biométricos.
- **Aprendizaje Federado:** el modelo aprende localmente y solo se comparten ajustes de parámetros (pesos) con el servidor central — nunca los datos crudos.

2. Anonimización y Desidentificación Biométrica

- **Eliminación de identificadores:** supresión o modificación de nombres, direcciones y datos sensibles mediante técnicas de desidentificación avanzada antes de cualquier procesamiento remoto.
- **Privacidad Diferencial:** ruido estadístico controlado que permite al modelo capturar patrones fonéticos globales, pero hace matemáticamente imposible reconstruir la identidad específica del hablante original.

3. Blindaje técnico y gobernanza

- **Cifrado extremo** en tránsito y en reposo, incluyendo los parámetros del propio modelo.
- **Control de acceso y auditoría:** roles y permisos estrictos con registros detallados de actividad y auditorías periódicas.
- **Dilema mejora vs. privacidad:** el aprendizaje por refuerzo requiere capturar interacciones del usuario para mejorar, pero inyecta riesgo de almacenamiento de firmas biométricas. Además, los LLMs pueden memorizar información del entrenamiento, actuando como bases de datos involuntarias de voces.
- **Transparencia:** informar explícitamente a los usuarios qué datos se recopilan y con qué fines, cumpliendo RGPD y el Reglamento de IA de la UE.

4. Tensión inevitable: el conflicto entre mejora continua y privacidad

Existe una contradicción estructural entre dos objetivos legítimos que todo sistema de voz en producción debe gestionar explícitamente:

Objetivo	Lo que requiere	Riesgo de privacidad
Mejorar la precisión del ASR	Capturar interacciones reales del usuario para ajuste por refuerzo (RLHF)	Almacenamiento de firmas vocales y contenido conversacional sensible
Personalización acústica	Retener perfil del hablante para adaptar el modelo a su voz específica	El perfil biométrico puede ser robado, vendido o usado para suplantación
Auditoría de equidad	Registrar predicciones y metadatos por subgrupo para detectar sesgos	Los metadatos combinados pueden re-identificar al hablante aunque el audio esté anonimizado
Fuga por memorización	El LLM puede 'recordar' frases o secretos dichos durante el entrenamiento	Extracción de datos privados mediante ataques de inversión del modelo (model inversion)

La solución no es elegir entre mejora y privacidad sino diseñar mecanismos donde ambas coexistan: Privacidad Diferencial durante el entrenamiento federado,

auditorías periódicas de memorización, y el principio de minimización de datos (recoger sólo lo estrictamente necesario para el propósito declarado).

Conclusión crítica: La única garantía real es un diseño donde el audio crudo sea efímero: capturado, convertido a tensor de características abstracto en milisegundos y destruido inmediatamente, permitiendo que la máquina extraiga el sentido lingüístico sin retener la huella dactilar de la identidad humana.

C. Sesgo y Accesibilidad: Estrategia Anti-exclusión

El sesgo no es un error de código sino un prejuicio sistemático derivado de entrenar con datos que favorecen el habla estándar. Se requiere gobernanza ética y arquitectura flexible.

1. Acondicionamiento del corpus

- **Aumento sintético (GANs + Time Stretching + Pitch Shifting):** robustece el modelo ante fatiga vocal y variaciones prosódicas regionales donde los datos reales son escasos.
- **Inclusión dialectal activa:** siguiendo iniciativas como el Proyecto ILENIA, integrar activamente variantes dialectales y lenguas cooficiales para que la máquina reconozca términos locales (ej. 'pantaloneta' vs. 'pantalones cortos').

2. Ajuste con enfoque en equidad

- **Instruction Tuning + LoRA:** mayor peso estadístico a muestras de habla no estándar; perfiles de accesibilidad portables por usuario que capturan variaciones acústicas finas sin olvido catastrófico.

3. Evaluación con métricas de dominio

- **WER desagregado:** calcular la tasa de error por acento, tipo de disartria y género. Un modelo con 5% de WER global puede tener 40% de error en una minoría — inaceptable para la equidad.
- **Model Cards:** documentar explícitamente las limitaciones del modelo ante diferentes patologías.
- **Lectura Fácil:** para usuarios con dificultades cognitivas, el LLM debe generar salidas con sintaxis y léxico simplificados sin perder la esencia del mensaje.

Conclusión crítica: La verdadera accesibilidad se logra cuando el sistema deja de exigir que el usuario se adapte a la máquina y usa la capacidad de los LLMs para inferir contexto semántico, compensando deficiencias en la señal física del habla.

D. Marco de Gobernanza Algorítmica

Los LLMs son arquitecturas de 'caja negra' cuya opacidad dificulta entender cómo se procesan señales biométricas y por qué se generan ciertas salidas. Se propone un marco alineado con el Reglamento de IA de la UE y el GDPR.

Eje	Herramientas / Mecanismos	Objetivo
Transparencia y explicabilidad	Model Cards; SHAP / LIME; Attention Maps (visualización de qué partes del espectrograma influyeron en cada transcripción)	Superar la opacidad de forma técnica y auditable — no solo declarativa
Auditoría y evaluación continua	Fairness Indicators; pruebas de penetración biométrica (spoofing); auditorías externas independientes	Detectar discriminación de acentos/dialectos, vulnerabilidades de suplantación y memorización de datos sensibles
Privacidad y consentimiento	Edge + Aprendizaje Federado; anonimización; consentimiento granular; derecho al olvido de huellas acústicas	Garantizar soberanía del dato biométrico — el usuario controla sus firmas vocales
Marco legal internacional	Reglamento IA-UE (sistemas de alto riesgo en educación/justicia); GDPR; supervisión de AESIA (España)	Cumplimiento normativo y rendición de cuentas pública (accountability)

Alineación con estándares internacionales

Este marco no opera en el vacío sino que se integra en la infraestructura global de supervisión de IA:

- **AESIA (España):** la Agencia Española de Supervisión de Inteligencia Artificial actúa como el órgano encargado de promover el uso confiable y responsable de estos sistemas, con competencia sancionadora sobre incumplimientos.
- **Reglamento de IA de la UE:** clasifica los sistemas ASR/TTS en contextos de educación y justicia como sistemas de 'alto riesgo', obligando a que sean suficientemente explicables y transparentes para generar confianza legítima en la ciudadanía. Esto incluye obligaciones de registro, documentación técnica y supervisión humana.
- **GDPR (Reglamento General de Protección de Datos):** la voz es un dato biométrico de categoría especial bajo el GDPR, requiriendo consentimiento explícito, base legal documentada y garantías técnicas y organizativas específicas que van más allá de las medidas estándar de seguridad.
- **Principio de responsabilidad proactiva (accountability):** no basta con cumplir la normativa; el desarrollador debe poder demostrar en cualquier momento que el sistema es conforme, lo que exige documentación continua, auditorías programadas y mecanismos de reporte de incidentes.

***Conclusión crítica:** Un marco de gobernanza efectivo no es un obstáculo a la innovación, sino la condición de posibilidad para que el habla artificial sea aceptada en la sociedad. Sin auditorías de equidad y soberanía del dato biométrico, los LLMs de voz corren el riesgo de institucionalizar prejuicios bajo la apariencia de eficiencia tecnológica.*